

# Calcul numeric

Cele mai mici pătrate. Regresie liniară.

Paul Irofti  
Andrei Pătrașcu  
Cristian Rusu

Departmentul de Informatică  
Facultatea de Matematică și Informatică  
Universitatea din București  
Email: `prenume.ume@fmi.unibuc.ro`



# Recapitulare: Sisteme de ecuații liniare

Fie sistemul

$$Ax = b$$


unde  $A \in \mathbb{R}^{m \times n}$  și  $b \in \mathbb{R}^n$  sunt date. Atunci sistemul este:

- ▶ Subdeterminat:  $m < n$ , posibil o infinitate de soluții
- ▶ Determinat:  $m = n$ , adesea soluție unică
- ▶ Supradeterminat:  $m > n$ , adesea nu are soluție

**Teoremă.** Sistemul  $Ax = b$  are soluție dacă și numai dacă  $b \in \text{Im}(A)$ .



# Recapitulare: Sisteme de ecuații liniare



# Recapitulare: Norme. Produs Scalar

**Produs scalar euclidian:**  $\langle x, y \rangle = x^T y = \sum_{i=1}^n x_i y_i$

- ▶ dacă  $x, y$  au norma unitate atunci  $x^T y = \cos(\theta)$ , unde  $\theta$  este unghiul format de  $x$  și  $y$
- ▶ în felul acesta, capătă sensul unei măsuri de similaritate (în opoziție cu distanța)

**Norme**  $\|\cdot\|$ : funcții care satisfac următoarele condiții

- ▶ pozitivitate:  $\|x\| > 0, \forall x \in \mathbb{R}^n, x \neq 0$
- ▶ omogenitate:  $\|\alpha x\| = |\alpha| \|x\|, \forall x \in \mathbb{R}^n, \alpha \in \mathbb{R}$
- ▶ inegalitatea triunghiului:  $\|x + y\| \leq \|x\| + \|y\|, \forall x, y \in \mathbb{R}^n$



# Cazul supradeterminat

Sistemele supradeterminate ( $m > n$ )  $\mathbf{Ax} = \mathbf{b}$  adesea nu au soluție pentru că  $\mathbf{b} \notin \text{Im}(\mathbf{A})$ .

**Scop:** Minimizarea erorii de aproximare  $\|\mathbf{Ax} - \mathbf{b}\|_p$ .

Alegeri comune sunt  $p = \{1, 2, \infty\}$  notate  $\ell_1$ ,  $\ell_2$ , respectiv  $\ell_\infty$ .

**Problema**  $\ell_2$  este cea mai rapid de rezolvat:

$$\min_{\mathbf{x} \in \mathbb{R}^n} \|\mathbf{Ax} - \mathbf{b}\|_2 \quad (1)$$

denumită problema celor mai mici pătrate (sau *least squares*).

**Soluții:**

- ▶ minimizare  $\phi(\mathbf{x}) = \frac{1}{2} \|\mathbf{Ax} - \mathbf{b}\|_2^2$  cu ajutorul gradientului  $\nabla \phi(\mathbf{x}) = 0$
- ▶ factorizare ortogonală  $\mathbf{A} = \mathbf{QR}$  a.î.  $\|(\mathbf{Q}^T \mathbf{A})\mathbf{x} - \mathbf{Q}^T \mathbf{b}\|_2$  se rezolvă ușor



# Ecuatiile normale

Minimizare cu ajutorul gradientului:

$$\min_{\mathbf{x} \in \mathbb{R}^n} \phi(\mathbf{x}) = \min_{\mathbf{x} \in \mathbb{R}^n} \frac{1}{2} \|\mathbf{Ax} - \mathbf{b}\|_2^2 \quad (2)$$

Rezolvăm ecuația  $\nabla \phi(\mathbf{x}) = 0$ :

$$\begin{aligned} \nabla \frac{1}{2} \|\mathbf{Ax} - \mathbf{b}\|_2^2 &= \nabla \frac{1}{2} \left( \sum_{i=1}^m \left[ (\mathbf{a}^i \mathbf{x}_i)^2 - 2\mathbf{a}^i \mathbf{x}_i \mathbf{b}_i + \mathbf{b}_i^2 \right] \right) \\ &= \frac{1}{2} \sum_{i=1}^m \left[ 2\mathbf{a}^{i2} \mathbf{x}_i - 2\mathbf{a}^i \mathbf{b}_i \right] = \mathbf{A}^T \mathbf{Ax} - \mathbf{A}^T \mathbf{b} \end{aligned}$$

Acestea sunt denumite ecuațiile normale:

$$\mathbf{A}^T \mathbf{Ax} = \mathbf{A}^T \mathbf{b} \quad (3)$$

unde

$$\mathbf{r}_{LS} = \mathbf{b} - \mathbf{Ax}_{LS} ; \rho_{LS} = \|\mathbf{Ax}_{LS} - \mathbf{b}\|_2 \quad (4)$$

reprezintă reziduul minim, respectiv, mărimea reziduului minim.



---

**Algorithm 1:** Ecuații normale CMMP

---

**Data:**  $\mathbf{A} \in \mathbb{R}^{m \times n}$  a.î.  $\text{rang}(\mathbf{A}) = n$  și  $\mathbf{b} \in \mathbb{R}^m$

**Result:** soluția CMMP  $\mathbf{x}_{LS} \in \mathbb{R}^n$

- 1 Calculează triunghiul inferior al matricei  $\mathbf{C} = \mathbf{A}^T \mathbf{A}$
  - 2 Actualizează vectorul țintă  $\mathbf{d} = \mathbf{A}^T \mathbf{b}$
  - 3 Calculează factorizarea Cholesky  $\mathbf{C} = \mathbf{G}\mathbf{G}^T$
  - 4 Rezolvă folosind LTRIS  $\mathbf{G}\mathbf{y} = \mathbf{d}$
  - 5 Rezolvă folosind UTRIS  $\mathbf{G}^T \mathbf{x}_{LS} = \mathbf{y}$
- 



---

**Algorithm 2:** Ecuații normale CMMP

---

**Data:**  $\mathbf{A} \in \mathbb{R}^{m \times n}$  a.î.  $\text{rang}(\mathbf{A}) = n$  și  $\mathbf{b} \in \mathbb{R}^m$

**Result:** soluția CMMP  $\mathbf{x}_{LS} \in \mathbb{R}^n$

- 1 Calculează triunghiul inferior al matricei  $\mathbf{C} = \mathbf{A}^T \mathbf{A}$   $O(\frac{mn^2}{2})$
  - 2 Actualizează vectorul țintă  $\mathbf{d} = \mathbf{A}^T \mathbf{b}$   $O(mn)$
  - 3 Calculează factorizarea Cholesky  $\mathbf{C} = \mathbf{G}\mathbf{G}^T$   $O(n^2)$
  - 4 Rezolvă folosind LTRIS  $\mathbf{G}\mathbf{y} = \mathbf{d}$   $O(n^2)$
  - 5 Rezolvă folosind UTRIS  $\mathbf{G}^T \mathbf{x}_{LS} = \mathbf{y}$   $O(n^2)$
- 





# Factorizarea QR

Factorizare ortogonală  $\mathbf{A} = \mathbf{QR}$  a.î.  $\|(Q^T \mathbf{A})\mathbf{x} - Q^T \mathbf{b}\|_2$  Pentru a obține matricea superior triunghiulară  $\mathbf{R} \in \mathbb{R}^{m \times n}$  se folosesc:

- ▶ rotații Givens
- ▶ reflector Householder
- ▶ eliminare Gaussiană (factorizare Doolittle)?

Aceste operații conduc la construcția matricei ortogonale  $\mathbf{Q}$ .

## Remarcă

O matrice  $\mathbf{Q} \in \mathbb{R}^{m \times m}$  este ortogonală dacă  $\mathbf{Q}^T \mathbf{Q} = \mathbf{Q} \mathbf{Q}^T = \mathbf{I}_m$ .  
Matricele ortogonale conservă norma  $\ell_2$ !

$$Q^T \mathbf{A} = \mathbf{R} = \begin{bmatrix} \mathbf{R}_1 \\ 0 \end{bmatrix} \begin{matrix} n \\ m-n \end{matrix} ; \quad Q^T \mathbf{b} = \begin{bmatrix} \mathbf{c} \\ \mathbf{d} \end{bmatrix} \begin{matrix} n \\ m-n \end{matrix} \quad (5)$$



# CMMP cu factorizare QR

Problema CMMP se reduce la

$$\min_{\mathbf{x} \in \mathbb{R}^n} \|\mathbf{Ax} - \mathbf{b}\|_2^2 = \min_{\mathbf{x} \in \mathbb{R}^n} \|\mathbf{Q}^T \mathbf{Ax} - \mathbf{Q}^T \mathbf{b}\|_2^2 = \min_{\mathbf{x} \in \mathbb{R}^n} \|\mathbf{R}_1 \mathbf{x} - \mathbf{c}\|_2^2 + \|\mathbf{d}\|_2^2 \quad (6)$$

unde  $\text{rang}(\mathbf{A}) = \text{rang}(\mathbf{R}_1) = n$

Problema se reduce la rezolvarea unui sistem superior triunghiular:

$$\mathbf{R}_1 \mathbf{x}_{LS} = \mathbf{c} ; \rho_{LS} = \|\mathbf{d}\|_2 \quad (7)$$

---

## Algorithm 3: CMMP cu factorizare QR

---

**Data:**  $\mathbf{A} \in \mathbb{R}^{m \times n}$  a.î.  $\text{rang}(\mathbf{A}) = n$  și  $\mathbf{b} \in \mathbb{R}^m$

**Result:** soluția CMMP  $\mathbf{x}_{LS} \in \mathbb{R}^n$

- 1 Calculează factorizarea  $\mathbf{A} = \mathbf{QR}$
  - 2 Aplică rotațiile/reflectorii primelor  $n$  poziții din  $\mathbf{b}$
  - 3 Rezolvă folosind UTRIS  $\mathbf{R}(1:n, 1:n) \mathbf{x}_{LS} = \mathbf{b}(1:n)$
- 



# CMMP cu factorizare QR – complexitate

Problema CMMP se reduce la

$$\min_{\mathbf{x} \in \mathbb{R}^n} \|\mathbf{Ax} - \mathbf{b}\|_2^2 = \min_{\mathbf{x} \in \mathbb{R}^n} \|\mathbf{Q}^T \mathbf{Ax} - \mathbf{Q}^T \mathbf{b}\|_2^2 = \min_{\mathbf{x} \in \mathbb{R}^n} \|\mathbf{R}_1 \mathbf{x} - \mathbf{c}\|_2^2 + \|\mathbf{d}\|_2^2 \quad (6)$$

unde  $\text{rang}(\mathbf{A}) = \text{rang}(\mathbf{R}_1) = n$

Problema se reduce la rezolvarea unui sistem superior triunghiular:

$$\mathbf{R}_1 \mathbf{x}_{LS} = \mathbf{c} ; \rho_{LS} = \|\mathbf{d}\|_2 \quad (7)$$

---

## Algorithm 4: CMMP cu factorizare QR

---

**Data:**  $\mathbf{A} \in \mathbb{R}^{m \times n}$  a.î.  $\text{rang}(\mathbf{A}) = n$  și  $\mathbf{b} \in \mathbb{R}^m$

**Result:** soluția CMMP  $\mathbf{x}_{LS} \in \mathbb{R}^n$

- 1 Calculează factorizarea  $\mathbf{A} = \mathbf{QR}$   $O(mn^2)$
  - 2 Aplică rotațiile/reflectorii primelor  $n$  poziții din  $\mathbf{b}$   $O(n^2)$
  - 3 Rezolvă folosind UTRIS  $\mathbf{R}(1:n, 1:n)\mathbf{x}_{LS} = \mathbf{b}(1:n)$   $O(n^2)$
- 



# Regresia liniară



# Recapitulare probabilități

Probabilitatea comună:

$$P(X = x_i, Y = y_j) = P(X = x_i \cap Y = y_j) = P(x_i, y_j) = \frac{n_{ij}}{N} \quad (8)$$

unde  $N$  reprezintă numărul total de evenimente, iar  $n_{ij}$  numărul de evenimente ce implică  $x_i$  și  $y_j$ .

Probabilitatea condițională:

$$P(X | Y) = \frac{|X \cap Y|}{|Y|} = \frac{\frac{|X \cap Y|}{N}}{\frac{|Y|}{N}} = \frac{P(X \cap Y)}{P(Y)} \quad (9)$$

Legea sumei și a produsului:

$$P(x) = \sum_{y \in \mathcal{Y}} P(x, y) ; P(x, y) = P(y | x)P(x) \quad (10)$$



# Recapitulare probabilități

Expectanță, covarianță, varianță:

$$\mu = E[X] = \sum_{i=1}^m x_i p_i ; \sum_{i=1}^m p_i = 1 \quad (11)$$

$$\Sigma = \text{Cov}(X, Y) = \frac{1}{m} \sum_{i=1}^m (x_i - E[X])(y_i - E[Y])^T \quad (12)$$

$$\sigma^2 = \text{Cov}(X, X) = \text{Var}(X) = E[(X - \mu)^2] \quad (13)$$

$$(14)$$

Distribuție gaussiană:

$$p(x \mid \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right) \quad (15)$$

Vom nota cu  $p(x) = \mathcal{N}(x \mid \mu, \sigma^2)$  sau  $X \sim \mathcal{N}(\mu, \sigma^2)$ .

Dacă  $x$  și  $y$  sunt variabile aleatoare gaussiene independente, atunci:

$$p(x + y) = \mathcal{N}(\mu_x + \mu_y, \sigma_x^2 + \sigma_y^2) \quad (16)$$



# Estimarea verosimilității maxime

Lega lui Bayes:

$$\underbrace{P(x | y)}_{a \text{ posteriori}} = \frac{\overbrace{P(y | x)}^{\text{verosimilitate a priori}} \overbrace{P(x)}^{\text{verosimilitate a priori}}}{\underbrace{P(y)}_{\text{dovezi}}} \quad (17)$$

Fie setul de  $m$  probabilități  $P(\mathbf{x}_i | \beta)$  condiționate de predictorii  $\beta$ .  
Atunci estimarea verosimilității maxime revine la:

$$\hat{\beta} = \arg \max_{\beta} P(\mathbf{X} | \beta) = \mathcal{L}_{\mathbf{X}}(\beta) = \prod_{i=1}^m P(\mathbf{x}_i | \beta) = \quad (18)$$

$$= \arg \max_{\beta} \log \mathcal{L}_{\mathbf{X}}(\beta) = \sum_{i=1}^m \log P(\mathbf{x}_i | \beta) = \quad (19)$$

$$= \arg \min_{\beta} - \sum_{i=1}^m \log P(\mathbf{x}_i | \beta) \quad (20)$$

unde  $f(\mathbf{x}_1, \dots, \mathbf{x}_m; \beta) = P(\mathbf{X} | \beta)$ .

În literatură: *Maximum Likelihood Estimation (MLE)*.



# Regresia liniară

**Scop:** stabilirea unei legături între variabila răspuns și una sau mai multe variabile de intrare (predictori).

$$y = f(x_1, x_2, \dots, x_n) + \varepsilon \quad (21)$$

- ▶ regresie liniară simplă – un singur predictor

$$y = \beta_0 + \beta_1 x + \varepsilon = \begin{bmatrix} 1, x \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix} + \varepsilon = \mathbf{x}^T \boldsymbol{\beta} + \varepsilon \quad (22)$$

- ▶ regresie liniară multiplă – mai mulți predictor

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_m x_m + \varepsilon = \mathbf{x}^T \boldsymbol{\beta} + \varepsilon \quad (23)$$

- ▶ regresie liniară univariată – răspuns scalar (precum sus)
- ▶ regresie liniară multivariată – răspuns vectorial


$$y_i = \mathbf{x}_i^T \boldsymbol{\beta} + \varepsilon_i = \beta_0 + \beta_1 x_{i,1} + \beta_2 x_{i,2} + \dots + \beta_m x_{i,m} + \varepsilon_i \quad (24)$$

$$\mathbf{y} = \mathbf{XB} + \mathbf{e} \quad (25)$$





# Proiecția



# Perspectiva probabilistică pentru formularea CMMP

Regresia liniară privește (21) dintr-o perspectivă probabilistică:

$$p(y \mid \mathbf{x}) = \mathcal{N}(y \mid f(\mathbf{x}), \sigma^2) \quad (26)$$

unde  $\mathbf{x}$  sunt intrările iar  $y$  sunt ieșirile perturbate cu un zgomot  $\varepsilon$  de medie  $\mu = 0$  și varianță  $\sigma^2$  (i.e.  $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ ).

Astfel (23), în care aproximăm  $f(\mathbf{x})$  cu ajutorul predicțiilor  $\beta$ , devine:

$$p(y \mid \mathbf{x}, \beta) = \mathcal{N}(y \mid \mathbf{x}^T \beta, \sigma^2) \quad (27)$$

$$\iff y = \mathbf{x}^T \beta + \varepsilon, \varepsilon \sim \mathcal{N}(0, \sigma^2) \quad (28)$$

## Remarcă

*Verosimilitatea lui (28) este PDF-ul funcției  $y$  evaluată în punctul  $\mathbf{x}^T \beta$ .*



# Estimarea parametrilor $\beta$

Fie regresia liniară din (28), dat setul de antrenare  $\{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$  a.î.  $y_i$  și  $y_j$  sunt independente (între ele) date intrările  $x_i$ , respectiv,  $x_j$  cu  $i \neq j$ . Atunci:

$$p(\mathcal{Y} \mid \mathcal{X}) = p(y_1, \dots, y_m \mid \mathbf{x}_1, \dots, \mathbf{x}_m, \beta) \quad (29)$$

$$= \prod_{i=1}^m p(y_i \mid \mathbf{x}_i, \beta) = \prod_{i=1}^m \mathcal{N}(y_i \mid \mathbf{x}_i^T \beta, \sigma^2) \quad (30)$$

## Remarcă

*Factorii și verosimilitatea lui (30) reprezintă distribuții Gausiene.*

## Remarcă

*Fie estimatorii optimi  $\beta^*$  și intrarea de test  $\mathbf{x}^*$ , atunci distribuția ieșirii  $y^*$  este  $\mathcal{N}(y^* \mid (\mathbf{x}^*)^T \beta^*)$*



Estimarea parametrilor  $\beta$  din (30) cu ajutorul estimării verosimilității maxime se face rezolvând problema de optimizare:

$$\beta_{ML} = \arg \max_{\beta} p(\mathcal{Y} \mid \mathcal{X}, \beta) \quad (31)$$

ce poate fi rescrisă drept o problemă de minimizare a sumei:

$$-\log p(\mathcal{Y} \mid \mathcal{X}, \beta) = -\log \prod_{i=1}^m p(y_i \mid \mathbf{x}_n, \beta) = -\sum_{i=1}^m \log p(y_i \mid \mathbf{x}_n, \beta) \quad (32)$$

unde termenii reprezintă distribuții gaussiene:

$$\log p(y_i \mid \mathbf{x}_n, \beta) = -\frac{1}{2\sigma^2} \left( y_n - \mathbf{x}_n^T \beta \right)^2 + C \quad (33)$$

unde  $C$  reprezintă termenii liberi (i.e. ce nu implică  $\beta$ ).



# Soluția MLE prin metoda gradient

Problema de optimizare devine

$$\mathcal{L}(\beta) = \frac{1}{2\sigma^2} - \sum_{i=1}^m \left( y_n - \mathbf{x}_n^T \beta \right)^2 \quad (34)$$

$$= \frac{1}{2\sigma^2} (\mathbf{y} - \mathbf{X}\beta)^T (\mathbf{y} - \mathbf{X}\beta) = \frac{1}{2\sigma^2} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 \quad (35)$$

## Remarcă

*Pentru a găsi punctul maximal în probleme de tipul (31) se folosesc metode de gradient.*

$$\frac{\partial \mathcal{L}}{\partial \beta} = \frac{\partial}{\partial \beta} \left( \frac{1}{2\sigma^2} (\mathbf{y} - \mathbf{X}\beta)^T (\mathbf{y} - \mathbf{X}\beta) \right) \quad (36)$$

$$= \frac{1}{2\sigma^2} \frac{\partial}{\partial \beta} \left( \mathbf{y}^T \mathbf{y} - 2\mathbf{y}^T \mathbf{X}\beta + \beta^T \mathbf{X}^T \mathbf{X}\beta \right) \quad (37)$$

$$= \frac{1}{\sigma^2} \left( -\mathbf{y}^T \mathbf{X} + \beta^T \mathbf{X}^T \mathbf{X} \right) \quad (38)$$



# Soluția MLE este soluția CMMP

Estimarea  $\beta_{ML}$  prin maximizarea verosimilității implică rezolvarea (39) în punctul zero:

$$\frac{\partial \mathcal{L}}{\partial \beta} = \mathbf{0} \iff \beta_{ML}^T \mathbf{X}^T \mathbf{X} = \mathbf{y}^T \mathbf{X} \quad (40)$$

$$\iff \beta_{ML}^T = \mathbf{y}^T \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} \quad (41)$$


$$\iff \beta_{ML} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} \quad (42)$$

## Remarcă

*Ecuatiile (41) reprezintă ecuațiile normale CMPP din (3) și sunt rezolvate eficient folosind Algoritmii 3 sau 5.*



# Regresia liniară unidimensională



# Regresia liniară bidimensională

